

INFORME TÉCNICO – FLUJO ANALÍTICO REPRODUCIBLE

Proyecto: Consolidación de entregas de proyectos – Campus Matriz y Extensión

Equipo: Mayra Sánchez, Josías Piña, Luis Valencia

Fecha de ejecución: 18 de agosto de 2026

Repositorio: G6_Taller_Clase3

1. OBJETIVO DEL PROYECTO

Diseñar e implementar un flujo analítico reproducible que integre los registros de entregas de proyectos provenientes de dos campus (Matriz y Extensión) con el catálogo maestro de estudiantes de la institución. El proceso incluye la consolidación estructural, el enriquecimiento mediante cruce relacional, la validación de calidad de datos, el cálculo de indicadores clave y la generación de salidas en múltiples formatos (CSV, JSON, Excel) para garantizar la transparencia, trazabilidad y sostenibilidad del análisis.

2. FUENTES DE DATOS UTILIZADAS

Se procesaron tres archivos fuente, todos ubicados en la carpeta data/raw/:

- **estudiantes_master.xlsx** – Catálogo maestro de 60 estudiantes con atributos: identificador, nombre, fecha de nacimiento, carrera, campus de origen, tipo de beca y estado académico.
- **entregas_campus_matriz.csv** – 150 registros de entregas correspondientes al campus Matriz.
- **entregas_campus_extension.csv** – 150 registros de entregas correspondientes al campus Extensión.

Cada archivo de entregas contiene: identificador de entrega, identificador de estudiante, fecha de subida, materia, tipo de proyecto, puntaje obtenido y estado de entrega.

3. METODOLOGÍA APLICADA

El flujo se estructuró en etapas secuenciales, todas documentadas y parametrizadas para garantizar reproducibilidad:

1. **Configuración del entorno** – Se definió un entorno Python con versiones fijas de librerías (pandas 3.0.5, numpy 2.5.2, openpyxl (versión no capturada por el script de entorno; se recomienda añadirla al print de diagnóstico)), usando rutas relativas con pathlib para independencia de sistema operativo.
2. **Preservación de archivos fuente** – Antes de la lectura, el script copia automáticamente (shutil.copy2) los tres archivos originales (estudiantes_master.xlsx, entregas_campus_matriz.csv y

entregas_campus_extension.csv) desde el directorio de trabajo hacia data/raw/. Esto garantiza que los insumos originales queden preservados dentro de la propia estructura del proyecto, en lugar de depender de una ubicación externa a la máquina de cada analista, reforzando la portabilidad y la trazabilidad del flujo.

3. **Lectura robusta de datos** – Se implementó una función genérica (leer_archivo_seguro) que soporta CSV, Excel y JSON, con manejo de excepciones y tipado explícito de columnas clave.
4. **Validación de integridad** – Cada DataFrame fue validado contra un conjunto de columnas requeridas; si faltaba alguna, el proceso se detenía con un error claro.
5. **Integración estructural (concatenación)** – Se añadió una columna de trazabilidad (campus) y se concatenaron los dos DataFrames de entregas, resultando en 300 registros. Se verificó la ausencia de duplicados en id_entrega.
6. **Integración relacional (merge)** – Se realizó un left join entre las entregas consolidadas y el catálogo de estudiantes, usando id_estudiante como clave. Se utilizó el parámetro validate='many_to_one' para garantizar la cardinalidad correcta y se generó un indicador de correspondencia (_merge) para auditar el cruce.
7. **Limpieza y calidad de datos** – Se contaron valores nulos en puntaje_obtenido, y se detectaron casos inconsistentes (estado “Pendiente” con puntaje, o “Revisión” sin puntaje). No se eliminaron registros, sino que se documentaron.
8. **Análisis exploratorio y agregaciones** – Se calcularon estadísticas descriptivas, promedios por campus, estado de entregas, top/bottom estudiantes, y promedios por materia y tipo de proyecto.
9. **Generación de resumen analítico** – Se agruparon los datos por estudiante y campus, obteniendo promedio, número de entregas y desviación estándar.
10. **Cálculo de indicadores de calidad del proceso** – Se midieron métricas como registros procesados, duplicados, huérfanos, nulos y distribución de estados.
11. **Exportación múltiple** – El dataset consolidado y el resumen analítico se guardaron en formatos CSV, JSON y Excel, con una marca de fecha para trazabilidad. Los huérfanos y los indicadores de calidad se exportaron por separado.

3.1. Desafíos y decisiones de diseño

Durante la implementación del flujo se enfrentaron los siguientes desafíos, que se resolvieron con decisiones técnicas documentadas:

- **Formato real del archivo de estudiantes** – El script incluye un bloque try/except que intenta primero la lectura con `pd.read_excel` y, si falla, recurre automáticamente a `pd.read_csv` con los parámetros adecuados. Esta estrategia defensiva evita que el flujo se detenga ante un archivo con formato inesperado. En la ejecución registrada, la carga se completó sin errores visibles, pero el bloque except no imprime una traza que confirme cuál de las dos rutas se ejecutó realmente; por lo tanto, no puede afirmarse con la evidencia actual si el archivo era un Excel genuino o un CSV con extensión `.xlsx`. Se recomienda añadir un mensaje explícito dentro de cada rama (por ejemplo, “leído como Excel” / “leído como CSV de respaldo”) para que esta decisión quede auditable, en línea con el principio de trazabilidad aplicado en el resto del flujo.
- **Manejo de registros huérfanos** – Se detectaron 5 entregas cuyo `id_estudiante` no tenía correspondencia en el catálogo (E555, E666, E777, E888, E999). En lugar de eliminar estos registros, se optó por conservarlos en el dataset final (con valores nulos en los atributos del catálogo) y exportar un archivo separado de huérfanos para su revisión manual. Esta decisión permite investigar las causas de la falta de correspondencia y mantener la trazabilidad completa de todas las entregas.
- **Trazabilidad del origen de los registros** – Al concatenar los archivos de entregas de ambos campus, se añadió explícitamente una columna `campus` con los valores `'matriz'` y `'extension'`. Esto permite diferenciar el origen de cada fila en análisis posteriores y facilita la comparación de rendimiento entre sedes, así como la auditoría de la procedencia de los datos.

Estas decisiones refuerzan la robustez y transparencia del proceso, asegurando que el flujo sea adaptable a variaciones en los datos de entrada y que la información se preserve para futuros análisis.

4. RESULTADOS OBTENIDOS

4.1. Integración y calidad de datos

- **Total de entregas consolidadas:** 300
- **Registros integrados tras merge:** 300
- **Correspondencia exitosa con catálogo:** 295 entregas (98,33%)

- **Huérfanos detectados (entregas sin estudiante en catálogo):** 5 (identificadores E555, E666, E777, E888, E999)
- **Duplicados en el catálogo:** 0 (se mantuvieron 60 estudiantes únicos)
- **Valores nulos en puntaje_obtenido:** 9 (3,00%), correspondientes a entregas en estado Pendiente.
- **Estados de entrega:**
 - Aprobado: 276
 - Revisión: 15
 - Pendiente: 9

No se encontraron entregas con estado “Pendiente” que tuvieran puntaje asignado, ni entregas en “Revisión” sin puntaje.

4.2. Estadísticas de puntajes (sobre 291 registros no nulos)

- **Media:** 90,35
- **Desviación estándar:** 6,63
- **Mínimo:** 60,00
- **Máximo:** 100,00
- **Percentil 25:** 87,00
- **Mediana (P50):** 91,00
- **Percentil 75:** 95,00

4.3. Rendimiento por campus

Campus	Promedio
Extensión	90,70
Matriz	89,99

Ambos campus muestran promedios muy similares, con una ligera ventaja para Extensión.

4.4. Top 5 estudiantes (promedio más alto)

Estudiante	Promedio
E999	100,00
E026	99,29
E058	99,00
E039	98,50

E043	98,33
------	-------

4.5. Bottom 5 estudiantes (promedio más bajo)

Estudiante	Promedio
E888	60,00
E012	70,33
E030	76,71
E020	81,80
E042	83,00

4.6. Promedio por materia

Materia	Promedio
Desarrollo de Software	90,75
DataOps	90,53
Sistemas de Bases de Datos	89,73

4.7. Promedio por tipo de proyecto

Tipo de proyecto	Promedio
Testing	91,51
Prototipo	91,48
Frontend	91,00
Pipeline	90,86
Deploy	90,26
Script SQL	89,94
Normalización	89,71
Modelado ER	89,55
API REST	89,14

5. INDICADORES DE CALIDAD DEL PROCESO (MÉTRICAS DE AUDITORÍA)

Indicador	Valor
Archivos procesados	3
Registros en catálogo	60
Registros en entregas Matriz	150
Registros en entregas Extensión	150
Registros consolidados (concat)	300
Registros integrados (merge)	300
Duplicados en catálogo eliminados	0

Claves sin correspondencia (huérfanos)	5
Nulos en puntaje_obtenido	9
Entregas Pendientes	9
Entregas en Revisión	15
Entregas Aprobadas	276
Dimensiones del dataset final (filas, cols)	300 × 14
Registros descartados	0
Archivos generados	8

Estos indicadores demuestran que el proceso de integración fue exitoso, con una tasa de correspondencia del 98,33% y un bajo porcentaje de valores faltantes en la variable principal (3%).

Adicionalmente, se incorporan dos indicadores que no constan en la tabla anterior:

- Registros descartados (0, ya que la integración se realizó con how='left' y ningún registro de entregas fue eliminado del flujo) y,
- Archivos generados (8 en total: 3 formatos del dataset integrado + 3 formatos del resumen por estudiante + el archivo de huérfanos + el propio archivo de indicadores de calidad).

Se deja constancia de que, en la versión actual del notebook, el valor de este último indicador queda inicializado en 0 dentro del diccionario de indicadores y no se actualiza tras la exportación, por lo que el archivo indicadores_calidad_20260819.csv reporta incorrectamente 0 en lugar de 8. Se recomienda corregir el código para que este conteo se calcule después de la exportación (por ejemplo, contando los archivos recién escritos en la carpeta data/processed/), de modo que el indicador exportado coincida con la evidencia real del proceso.

6. ESTRATEGIA DE REPRODUCIBILIDAD

Para asegurar que cualquier analista pueda reproducir el flujo en su propio entorno, se implementaron las siguientes buenas prácticas:

- **Entorno virtual** – Se recomienda crear un entorno aislado con python -m venv .venv y activarlo según el sistema operativo.
- **Dependencias fijas** – Todas las librerías están listadas en requirements.txt con versiones específicas.
- **Rutas relativas** – El código utiliza pathlib para construir rutas relativas al directorio de trabajo, por lo que funciona en cualquier máquina.

- **Control de versiones** – El repositorio incluye un archivo .gitignore que excluye datos crudos, archivos temporales y entornos virtuales, evitando la exposición de información sensible. Adicionalmente, el repositorio G6_Taller_Clase3 se alojó en GitHub implementando una estrategia de ramas (branches) para trabajo colaborativo: además de la rama principal main, cada integrante del equipo desarrolló en su propia rama (Luis, Josias y Mayra), lo que permitió avanzar en paralelo sobre distintas partes del flujo sin sobrescribir el trabajo de los demás y facilitó la revisión de cambios antes de integrarlos a la rama principal.




Figura 1. Ramas del repositorio G6_Taller_Clase3 en GitHub: rama principal (main) y ramas individuales de cada integrante (Luis, Josias, Mayra) para el desarrollo colaborativo del flujo.

- **Documentación completa** – Se incluye un README.md que detalla el propósito, estructura, instalación, ejecución y salidas.
- **Operaciones deterministas** – No se utilizan procesos aleatorios; todas las transformaciones son repetibles y las salidas incluyen la fecha de ejecución.

7. ARCHIVOS GENERADOS (ubicados en data/processed/)

- dataset_integrado_20260819.csv / .json / .xlsx – Dataset completo integrado.
- resumen_estudiantes_20260819.csv / .json / .xlsx – Resumen por estudiante y campus.
- huerfanos_20260816.csv – Entregas sin correspondencia en el catálogo.
- indicadores_calidad_20260819.csv – Métricas de calidad del proceso.

8. CONCLUSIONES Y RECOMENDACIONES

- El flujo analítico diseñado cumple con los objetivos de integración, validación y generación de indicadores, y es totalmente reproducible.

- La calidad de los datos es alta: el 98,33% de las entregas tienen correspondencia con el catálogo, y solo el 3% de los puntajes están ausentes (todos asociados a estados Pendiente).
- Los promedios por campus son muy similares, lo que sugiere un desempeño homogéneo entre ambas sedes.
- Se recomienda revisar los 5 registros huérfanos (E555, E666, E777, E888, E999) para actualizar el catálogo o verificar la correcta asignación de estudiantes. Cabe destacar que dos de estos identificadores, E999 y E888, coinciden exactamente con los casos extremos del ranking de promedios (mejor y peor promedio, respectivamente, con 100,00 y 60,00), lo que aumenta la prioridad de su revisión: podría tratarse de registros de prueba o sintéticos incorporados por error al sistema de entregas, en lugar de estudiantes reales no matriculados.
- Los estudiantes con bajo promedio (especialmente E888, E012 y E030) podrían beneficiarse de planes de acompañamiento académico.
- El código y la documentación permiten escalar el análisis a más fuentes de datos o períodos sin pérdida de reproducibilidad.

Link del repositorio:

https://github.com/luiscarlos1986vr-del/G6_Taller_Clase3/tree/main